

Machine Learning Avec Python

Section 1 : Introduction au Machine Learning
Section 2 : Implémentation d'algorithmes de ML en Python
Section 3 : Regression simple linéaire
Section 4 : Regression multiple linéaire
Section 5 : Algorithme de classification: K-(Plus Proches) Voisins
Section 6 : Algorithme de classification : Arbre de décision
Section 7 : Algorithme de classification : Regression logistique
Section 8 : Clustering
Section 9 : Systeme de recommandation
Section 10: Conclusion



Introduction au Machine Learning

Qu'est ce que le Machine Learning?

- Machine learning est une forme d'intelligence artificielle, où l'on apprend à la machine à effectuer des tâches sans être explicitement programmée.

Caracteristiques du Machine Learning:

1. Apprend la relation entre les données.
2. Il peut prédire des événements pour d'autres données.
3. Améliorer les performances par rapport à l'expérience.





Introduction au Machine Learning

Applications

- ☀ Diagnostique Med
- ☀ Voitures autonomes
- ☀ Filtrage de spam
- ☀ Trading en bourse
- ☀ Traduction automatique
- ☀ Recommandation produit
- ☀ Prediction de circulation
- ☀ Reconnaissance d'image
- ☀ Reconnaissance vocale

Et plein d'autres !



Introduction au Machine Learning

Application du vrai monde


- ★ Detection de cancer et de tumeurs au cerveau
- ★ Les voitures autonomes de chez tesla
- ★ Gmail filtre les spams des emails
- ★ Traducteur google
- ★ Netflix, YouTube, Amazon, et autres entreprises

Google maps, détection des visages pour déverrouiller un appareil, Siri, Cortana, Alexa et toutes ces technologies utilisent le machine learning en fond.



Machine Learning

Méthode de Machine learning






Machine Learning

Qu'est ce que l'apprentissage supervisé

Le terme "supervisé" désigne l'action de surveiller et de diriger la réalisation d'un travail, d'un projet ou d'une opération. Il utilise des données de formation étiquetées et une collection d'échantillons de formation pour estimer une fonction.






Machine Learning

Qu'est ce que l'apprentissage non supervisé ?


L'apprentissage non supervisé est un type d'apprentissage automatique dans lequel les données d'apprentissage sont fournies au système sans étiquettes ou valeurs pré-assignées.





Machine Learning

Apprentissage supervisé vs apprentissage non supervisé





Quiz Time

Lequel des énoncés suivants est VRAI au sujet de l'apprentissage automatique non supervisé ?

- 1) L'apprentissage non supervisé comprend des algorithmes sans résultats préexistants.*
- 2) Des algorithmes d'apprentissage sans contrôle de la qualité de leurs prédictions.*
- 3) un apprentissage machine semi-autonome où les chercheurs contrôlent certaines parties du processus de modélisation.*
- 4) un apprentissage automatique entièrement autonome, sans intervention*



Quiz Time

Lequel des énoncés suivants est VRAI au sujet de l'apprentissage automatique non supervisé ?

- 1) L'apprentissage non supervisé comprend des algorithmes sans résultats préexistants.
- 2) Des algorithmes d'apprentissage sans contrôle de la qualité de leurs prédictions.
- 3) un apprentissage machine semi-autonome où les chercheurs contrôlent certaines parties du processus de modélisation.
- 4) un apprentissage automatique entièrement autonome, sans intervention



Langage de programmation pour le Machine Learning

Python

Python est un langage de programmation efficace et largement utilisé qui est devenu dernièrement le langage de prédilection des data scientists.



Libraries de Python

Voici les quelques bibliothèques de Python.





Langage de programmation pour le Machine Learning

Libraries de Python



Numpy permet de traiter de grands tableaux et matrices multidimensionnels, ainsi qu'une large collection de fonctions mathématiques de haut niveau pour opérer sur ces tableaux.

Scipy est utilisé pour le calcul scientifique et le calcul technique. SciPy contient des modules pour l'optimisation, l'algèbre linéaire, l'intégration, les fonctions spéciales, le traitement des signaux et des images, ainsi que d'autres tâches courantes en sciences et en ingénierie.

Matplotlib est une bibliothèque de traçage, et elle est facile à utiliser avec Numpy parce que sa partie numérique est intégrée à Numpy.




Langage de programmation pour le Machine Learning

Libraries de Python

pandas

$$y_i t = \beta' x_{it} + \mu_i + \epsilon_{it}$$



Pandas est conçu pour la manipulation et l'analyse de données. Il offre notamment des structures de données et des opérations pour la manipulation de tableaux numériques et de séries chronologiques.

Scikit-learn (également connu sous le nom de sklearn) est une bibliothèque libre d'apprentissage automatique pour le langage de programmation Python. Elle propose divers algorithmes de classification, de régression et de regroupement. Elle est conçue pour interagir avec les bibliothèques numériques et scientifiques Python NumPy et SciPy.



Introduction à Python

Qu'est ce que Python?

- Python est l'un des langages de programmation les plus populaires, créé par **Guido van Rossum** et publié en 1991.
- Python est un langage de programmation interprété, par opposition à un langage de programmation compilé.



Pourquoi python?


- Python est un langage convivial pour les débutants en raison de sa syntaxe simplifiée, proche du langage naturel.
- Il a été conçu pour écrire un code clair et logique pour les projets de petite et grande envergure.
- Il est largement utilisé dans l'industrie pour le développement de logiciels, la science des données, l'intelligence artificielle et l'apprentissage automatique.



Installer Python

Python3 vs Python2


- Python2 est une version obsolète de Python. Python3 est la version actuelle et est très demandée.
- Dans ce cours, nous allons apprendre Python3 .





Mettre en place Python– Windows (1/8)


- Aller sur: <https://www.python.org/>





Mettre en place Python – Windows (2/8)


- Cliquer sur Downloads.





Mettre en place Python – Windows (3/8)


- Cela vous montrera la dernière version de Python3 pour votre système d'exploitation. Téléchargez-la.





Mettre en place Python – Windows (4/8)


- Une fois installé, cliquer sur Open.





Mettre en place Python – Windows (5/8)


- L'assistant d'installation s'ouvre. Assurez-vous que la case "Add Python 3.9 to Path" est cochée. Cliquer sur Install now.





Mettre en place Python – Windows (6/8)


- Cela va prendre un peu de temps.





Mettre en place Python – Windows (7/8)


- Une fois installé, écrire python dans votre var de recherche et cliquer sur 'IDLE (Python 3.9 64-bit)'.





Mettre en place Python – Windows (8/8)

- Cela va ouvrir l’IDLE de Python. Ecrire `print("Hello")` et appuyer sur Enter pour executer.




```
IDLE Shell 3.9.7
File Edit Shell Debug Options Window Help
Python 3.9.7 (tags/v3.9.7:1016ef3, Aug 30 2021, 20:19:38) [MSC v.1929 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>> print("Hello")
Hello
>>> |
```




Mettre en place Python – Mac (1/13)


- Aller sur: <https://www.python.org/>





Mettre en place Python – Mac (2/13)


- Appuyer sur Downloads.





Mettre en place Python – Mac (3/13)

- Cela vous montrera la dernière version de Python3 pour votre système d'exploitation. Téléchargez-la





Mettre en place Python – Mac (4/13)

- Une fois installé, cliquer sur Open.

The screenshot shows the Python.org website's download page for Mac OS X. The page has a dark blue header with the Python logo and navigation links: Python, PSF, Docs, About, Downloads, Documentation, Community, Success Stories, News, and Events. The main content area is dark blue with a yellow and white striped parachute graphic. The text 'Download the latest version for Mac OS X' is prominently displayed, followed by a yellow button labeled 'Download Python 3.9.1'. Below this, there are links for other operating systems: 'Looking for Python with a different OS? Python for [Windows](#), [Linux/UNIX](#), [Mac OS X](#), [Other](#)'. There are also links for development versions: 'Want to help test development versions of Python? [Prereleases](#), [Docker images](#)'. At the bottom, there is a section titled 'Active Python Releases' with a link to the 'Python Developer's Guide'. Below this is a table with the following data:

Python version	Maintenance status	First released	End of support	Release schedule
3.9	bugfix	2020-10-05	2025-10	PEP 596



Setting Up Python – Mac (5/13)

- Appuyer sur Continue





Mettre en place Python – Mac (6/13)

- Appuyer sur Continue





Mettre en place Python – Mac (7/13)


- Cliquer sur Continue.





Mettre en place Python – Mac (8/13)

- Lire et accepter l'accord de licence.





Mettre en place Python – Mac (9/13)

- Cliquer sur continue.





Mettre en place Python – Mac (10/13)


- Cliquer sur install. Si demandé, entrer votre mot de passe.





Mettre en place Python – Mac (11/13)


- Attendre la fin de l'installation.





Mettre en place Python – Mac (12/13)


- Une fois installé, chercher l'IDLE dans votre Bureau et appuyer dessus.





Mettre en place Python – Mac (13/13)

- Cela va ouvrir l’IDLE de Python. Ecrire `print(“Hello”)` et appuyer sur Enter pour executer.




```
Python 3.9.1 (v3.9.1:1e5d33e9b9, Dec 7 2020, 12:10:52)
[Clang 6.0 (clang-600.0.57)] on darwin
Type "help", "copyright", "credits" or "license()" for more information.
WARNING: The system preference "Prefer tabs when opening documents" is set to
"Always". This will cause various problems with IDLE. For the best experience,
change this setting when running IDLE (via System Preferences -> Dock).
>>> print('Hello World')
Hello World
>>>
>>>
>>> |
```

Ln: 11 Col: 4



Jupyter Notebook

- Jupyter Notebook est une application web qui vous permet de créer des documents pouvant contenir du code, des visualisations et du texte narratif.
- Elle est très populaire et est largement utilisée en science des données, en intelligence artificielle et en apprentissage automatique.
- Un notebook porte l'extension .ipynb.




Alternatives au Jupyter Notebook

- Google Colaboratory est une alternative à Jupyter Notebook et ne nécessite aucun téléchargement.



Anaconda pour Windows (2/13)


- Une fois téléchargé, cliquer sur Open.





Anaconda pour Windows (3/13)


- Une installation Wizard va s'ouvrir.
- Cliquer sur Next.





Anaconda pour Windows (4/13)


- Lire le contrat de licence et cliquer sur Agree





Anaconda pour Windows (5/13)


- Cliquer sur Next.





Anaconda pour Windows (6/13)


- Choisir la destination et cliquer sur Next.





Anaconda pour Windows (7/13)


- Cliquer sur Install.





Anaconda pour Windows (8/13)


- Attendre que l'installation se finisse et cliquer sur Next





Anaconda pour Windows (9/13)


- Cliquer sur Finish.





Anaconda pour Windows (10/13)


- Pour lancer le Jupyter Notebook, chercher anaconda dans le navigateur et l'ouvrir.





Anaconda pour Windows (11/13)


- L'écran suivant va s'ouvrir.
- D'ici, lancer le Jupyter Notebook.





Anaconda pour Windows (12/13)


- Ceci lancera Jupyter Notebook dans votre navigateur par défaut.
- Cliquer sur New -> Python3 pour créer un nouveau Notebook.





Anaconda pour Windows (13/13)


- Voilà à quoi un notebook ressemble.





Anaconda pour Mac (1/14)


- Aller sur : <https://www.anaconda.com/>
- Appuyer sur Get Started.





Anaconda pour Mac (2/14)


- Cliquer sur Download Anaconda Installers.





Anaconda pour Mac (3/14)


- Télécharger le graphical installer pour Mac.





Anaconda pour Mac (4/14)


- Une fois le téléchargement effectué, lancez l'assistant d'installation en double-cliquant sur le fichier.
- Cliquer sur Continue.





Anaconda pour Mac (5/14)


- Lire le fichier Read Me et cliquer sur continue.





Anaconda pour Mac (6/14)


- Read the License Agreement and click continue.





Anaconda pour Mac (7/14)


- Selectionner la destination et cliquer sur Continue.





Anaconda pour Mac (8/14)


- Cliquer sur Install.





Anaconda pour Mac (9/14)


- Cliquer sur Continue.





Anaconda pour Mac (10/14)


- Une fois l'installation finie, cliquer sur close.





Anaconda pour Mac (11/14)


- Ouvrir votre bureau et cliquer sur Anaconda Navigator pour le lancer.





Anaconda pour Mac (12/14)


- Lancer Jupyter Notebook. Cela va prendre un peu de temps à s'ouvrir





Anaconda pour Mac (13/14)


- Ceci lancera Jupyter Notebook dans votre navigateur par défaut.
- Cliquez sur New -> Python3 pour créer un nouveau Notebook.





Anaconda pour Mac (14/14)

- C'est à cela que le Jupyter Notebook ressemble.





Anaconda pour Ubuntu (1/11)

- Ouvrir votre terminal, coller la commande suivante et appuyer sur entrer.
sudo apt install libgl1-mesa-glx libegl1-mesa libxrandr2 libxrandr2 libxss1 libxcursor1 libxcomposite1 libasound2 libxi6 libxtst6
- Taper votre mot de passer et taper entrer.

```
waqar@waqar-N750BU: ~  
waqar@waqar-N750BU:~$ sudo apt install libgl1-mesa-glx libegl1-mesa libxrandr2 l  
ibxrandr2 libxss1 libxcursor1 libxcomposite1 libasound2 libxi6 libxtst6  
[sudo] password for waqar: 
```



Anaconda pour Ubuntu (2/11)

- Puis écrire la commande suivante et taper entrer.
wget https://repo.anaconda.com/archive/Anaconda3-2020.11-Linux-x86_64.sh -O
~/Downloads/Anaconda3-2020.11-Linux-x86_64.sh

```
waqar@waqar-N750BU: ~  
Preparing to unpack .../libasound2_1.2.2-2.1ubuntu2.4_amd64.deb ...  
Unpacking libasound2:amd64 (1.2.2-2.1ubuntu2.4) over (1.2.2-2.1ubuntu2.3) ...  
Preparing to unpack .../libasound2-data_1.2.2-2.1ubuntu2.4_all.deb ...  
Unpacking libasound2-data (1.2.2-2.1ubuntu2.4) over (1.2.2-2.1ubuntu2.3) ...  
Preparing to unpack .../libegl1-mesa_21.0.3-0ubuntu0.3~20.04.2_amd64.deb ...  
Unpacking libegl1-mesa:amd64 (21.0.3-0ubuntu0.3~20.04.2) over (20.2.6-0ubuntu0.20.04.1) ...  
Preparing to unpack .../libgl1-mesa-glx_21.0.3-0ubuntu0.3~20.04.2_amd64.deb ...  
Unpacking libgl1-mesa-glx:amd64 (21.0.3-0ubuntu0.3~20.04.2) over (20.2.6-0ubuntu0.20.04.1) ...  
Setting up libegl1-mesa:amd64 (21.0.3-0ubuntu0.3~20.04.2) ...  
Setting up libasound2-data (1.2.2-2.1ubuntu2.4) ...  
Setting up libgl1-mesa-glx:amd64 (21.0.3-0ubuntu0.3~20.04.2) ...  
Setting up libasound2:amd64 (1.2.2-2.1ubuntu2.4) ...  
Processing triggers for libc-bin (2.31-0ubuntu9.2) ...  
waqar@waqar-N750BU:~$ wget https://repo.anaconda.com/archive/Anaconda3-2020.11-Linux-x86_64.sh -O ~/Downloads/Anaconda3-2020.11-Linux-x86_64.sh  
--2021-10-03 12:51:56-- https://repo.anaconda.com/archive/Anaconda3-2020.11-Linux-x86_64.sh  
Resolving repo.anaconda.com (repo.anaconda.com)... 104.16.130.3, 104.16.131.3, 2606:4700::6810:8303, ...  
Connecting to repo.anaconda.com (repo.anaconda.com)|104.16.130.3|:443... connected.  
HTTP request sent, awaiting response... 200 OK  
Length: 554535580 (529M) [application/x-sh]  
Saving to: '/home/waqar/Downloads/Anaconda3-2020.11-Linux-x86_64.sh'  
x86_64.sh 16%[==>] 85.64M 7.34MB/s eta 61s
```



Anaconda pour Ubuntu (3/11)

- Ensuite écrire cette commande et taper entrer
`cd ~/Downloads`

```
waqar@waqar-N750BU: ~/Downloads
4.1) ...
Preparing to unpack .../libgl1-mesa-glx_21.0.3-0ubuntu0.3~20.04.2_amd64.deb ...
Unpacking libgl1-mesa-glx:amd64 (21.0.3-0ubuntu0.3~20.04.2) over (20.2.6-0ubuntu0.2
0.04.1) ...
Setting up libegl1-mesa:amd64 (21.0.3-0ubuntu0.3~20.04.2) ...
Setting up libasound2-data (1.2.2-2.1ubuntu2.4) ...
Setting up libgl1-mesa-glx:amd64 (21.0.3-0ubuntu0.3~20.04.2) ...
Setting up libasound2:amd64 (1.2.2-2.1ubuntu2.4) ...
Processing triggers for libc-bin (2.31-0ubuntu9.2) ...
waqar@waqar-N750BU:~$ wget https://repo.anaconda.com/archive/Anaconda3-2020.11-Linu
x-x86_64.sh -O ~/Downloads/Anaconda3-2020.11-Linux-x86_64.sh
--2021-10-03 12:51:56-- https://repo.anaconda.com/archive/Anaconda3-2020.11-Linux-
x86_64.sh
Resolving repo.anaconda.com (repo.anaconda.com)... 104.16.130.3, 104.16.131.3, 2606
:4700::6810:8303, ...
Connecting to repo.anaconda.com (repo.anaconda.com)|104.16.130.3|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 554535580 (529M) [application/x-sh]
Saving to: '/home/waqar/Downloads/Anaconda3-2020.11-Linux-x86_64.sh'

/home/waqar/Download 100%[=====>] 528.85M  7.25MB/s   in 75s

2021-10-03 12:53:12 (7.08 MB/s) - '/home/waqar/Downloads/Anaconda3-2020.11-Linux-x8
6_64.sh' saved [554535580/554535580]

waqar@waqar-N750BU:~$ cd ~/Downloads
waqar@waqar-N750BU:~/Downloads$
```



Anaconda pour Ubuntu (4/11)

- Puis cette commande et appuyer sur entrer
`sudo chmod +x Anaconda3-2020.11-Linux-x86_64.sh`

```
waqar@waqar-N750BU: ~/Downloads
Preparing to unpack .../libgl1-mesa-glx_21.0.3-0ubuntu0.3~20.04.2_amd64.deb ...
Unpacking libgl1-mesa-glx:amd64 (21.0.3-0ubuntu0.3~20.04.2) over (20.2.6-0ubuntu0.2
0.04.1) ...
Setting up libegl1-mesa:amd64 (21.0.3-0ubuntu0.3~20.04.2) ...
Setting up libasound2-data (1.2.2-2.1ubuntu2.4) ...
Setting up libgl1-mesa-glx:amd64 (21.0.3-0ubuntu0.3~20.04.2) ...
Setting up libasound2:amd64 (1.2.2-2.1ubuntu2.4) ...
Processing triggers for libc-bin (2.31-0ubuntu9.2) ...
waqar@waqar-N750BU:~$ wget https://repo.anaconda.com/archive/Anaconda3-2020.11-Linu
x-x86_64.sh -O ~/Downloads/Anaconda3-2020.11-Linux-x86_64.sh
--2021-10-03 12:51:56-- https://repo.anaconda.com/archive/Anaconda3-2020.11-Linux-
x86_64.sh
Resolving repo.anaconda.com (repo.anaconda.com)... 104.16.130.3, 104.16.131.3, 2606
:4700::6810:8303, ...
Connecting to repo.anaconda.com (repo.anaconda.com)|104.16.130.3|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 554535580 (529M) [application/x-sh]
Saving to: '/home/waqar/Downloads/Anaconda3-2020.11-Linux-x86_64.sh'

/home/waqar/Download 100%[=====] 528.85M  7.25MB/s   in 75s

2021-10-03 12:53:12 (7.08 MB/s) - '/home/waqar/Downloads/Anaconda3-2020.11-Linux-x8
6_64.sh' saved [554535580/554535580]

waqar@waqar-N750BU:~$ cd ~/Downloads
waqar@waqar-N750BU:~/Downloads$ sudo chmod +x Anaconda3-2020.11-Linux-x86_64.sh
waqar@waqar-N750BU:~/Downloads$
```



Anaconda pour Ubuntu (5/11)

- Puis cette commande et entrer
./Anaconda3-2020.11-Linux-x86_64.sh
- Une fois affiché, appuyer sur entrer pour continuer.

```
Processing triggers for libc-bin (2.31-0ubuntu9.2) ...
waqar@waqar-N750BU:~$ wget https://repo.anaconda.com/archive/Anaconda3-2020.11-Linux-x86_64.sh -O ~/Downloads/Anaconda3-2020.11-Linux-x86_64.sh
--2021-10-03 12:51:56-- https://repo.anaconda.com/archive/Anaconda3-2020.11-Linux-x86_64.sh
Resolving repo.anaconda.com (repo.anaconda.com)... 104.16.130.3, 104.16.131.3, 2606:4700::6810:8303, ...
Connecting to repo.anaconda.com (repo.anaconda.com)|104.16.130.3|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 554535580 (529M) [application/x-sh]
Saving to: '/home/waqar/Downloads/Anaconda3-2020.11-Linux-x86_64.sh'

/home/waqar/Download 100%[=====] 528.85M  7.25MB/s   in 75s

2021-10-03 12:53:12 (7.08 MB/s) - '/home/waqar/Downloads/Anaconda3-2020.11-Linux-x86_64.sh' saved [554535580/554535580]

waqar@waqar-N750BU:~$ cd ~/Downloads
waqar@waqar-N750BU:~/Downloads$ sudo chmod +x Anaconda3-2020.11-Linux-x86_64.sh
waqar@waqar-N750BU:~/Downloads$ ./Anaconda3-2020.11-Linux-x86_64.sh

Welcome to Anaconda3 2020.11

In order to continue the installation process, please review the license
agreement.
Please, press ENTER to continue
>>> 
```



Anaconda pour Ubuntu (6/11)

- Appuyez sur la touche Enter pour faire défiler l'accord de licence..
- Après avoir lu l'accord, tapez oui dans l'invite et appuyez sur la touche Entrée..

```
waqar@waqar-N750BU: ~/Downloads
A network authentication protocol designed to provide strong authentication for
client/server applications by using secret-key cryptography.

cryptography
  A Python library which exposes cryptographic recipes and primitives.

pycryptodome
  A fork of PyCrypto. It is a self-contained Python package of low-level cryptogr
aphic primitives.

pycryptodomex
  A stand-alone version of pycryptodome.

libsodium
  A software library for encryption, decryption, signatures, password hashing and
more.

pynacl
  A Python binding to the Networking and Cryptography library, a crypto library w
ith the stated goal of improving usability, security and speed.


Last updated September 28, 2020

Do you accept the license terms? [yes|no]
[no] >>> yes
```



Anaconda pour Ubuntu (7/11)

- Le programme d'installation d'Anaconda vous demandera où vous voulez installer Anaconda. Nous vous suggérons d'appuyer sur la touche Entrée pour l'installer dans le répertoire personnel.
- Après un certain temps, Anaconda sera installé sur votre machine.



```
waqar@waqar-N750BU: ~/Downloads
A stand-alone version of pycryptodome.

libsodium
  A software library for encryption, decryption, signatures, password hashing and
  more.

pynacl
  A Python binding to the Networking and Cryptography library, a crypto library w
  ith the stated goal of improving usability, security and speed.

Last updated September 28, 2020

Do you accept the license terms? [yes|no]
[no] >>> yes

Anaconda3 will now be installed into this location:
/home/waqar/anaconda3

- Press ENTER to confirm the location
- Press CTRL-C to abort the installation
- Or specify a different location below

[/home/waqar/anaconda3] >>>
PREFIX=/home/waqar/anaconda3
█
```



Anaconda pour Ubuntu (8/11)

- Une fois l'installation terminée, il vous sera demandé "Do you wish the installer to initialize Anaconda3 by running conda init?" taper " yes" et appuyer sur Entrée. Le programme d'installation terminera le processus d'installation.


```
waqar@waqar-N750BU: ~/Downloads
wheel                pkgs/main/noarch::wheel-0.35.1-py_0
widgetsnbextension  pkgs/main/linux-64::widgetsnbextension-3.5.1-py38_0
wrapt                 pkgs/main/linux-64::wrapt-1.11.2-py38h7b6447c_0
wurlitzer             pkgs/main/linux-64::wurlitzer-2.0.1-py38_0
xlrd                  pkgs/main/noarch::xlrd-1.2.0-py_0
xlsxwriter            pkgs/main/noarch::xlsxwriter-1.3.7-py_0
xlwt                  pkgs/main/linux-64::xlwt-1.3.0-py38_0
xmldict               pkgs/main/noarch::xmldict-0.12.0-py_0
xz                    pkgs/main/linux-64::xz-5.2.5-h7b6447c_0
yaml                  pkgs/main/linux-64::yaml-0.2.5-h7b6447c_0
yapf                  pkgs/main/noarch::yapf-0.30.0-py_0
zeromq                pkgs/main/linux-64::zeromq-4.3.3-he6710b0_3
zict                  pkgs/main/noarch::zict-2.0.0-py_0
zippp                 pkgs/main/noarch::zippp-3.4.0-pyhd3eb1b0_0
zlib                  pkgs/main/linux-64::zlib-1.2.11-h7b6447c_3
zope                  pkgs/main/linux-64::zope-1.0-py38_1
zope.event            pkgs/main/linux-64::zope.event-4.5.0-py38_0
zope.interface        pkgs/main/linux-64::zope.interface-5.1.2-py38h7b6447c_0
zstd                  pkgs/main/linux-64::zstd-1.4.5-h9ceee32_0

Preparing transaction: done
Executing transaction: done
installation finished.
Do you wish the installer to initialize Anaconda3
by running conda init? [yes|no]
[no] >>> yes
```




Anaconda pour Ubuntu (9/11)

- Pour lancer Jupyter Notebook, redémarrez votre terminal.
- Vous verrez (base) écrit devant le nom de votre répertoire personnel.
- Tapez "jupyter notebook" sans les guillemets et appuyez sur Entrée.
- Après quelques minutes, Jupyter Notebook sera lancé sur votre navigateur par défaut.




```
waqar@waqar-N750BU: ~  
(base) waqar@waqar-N750BU:~$ jupyter notebook  
[I 13:04:48.077 NotebookApp] JupyterLab extension loaded from /home/waqar/anaconda3/lib/python3.8/site-packages/jupyterlab  
[I 13:04:48.077 NotebookApp] JupyterLab application directory is /home/waqar/anaconda3/share/jupyter/lab  
[I 13:04:48.080 NotebookApp] Serving notebooks from local directory: /home/waqar  
[I 13:04:48.080 NotebookApp] Jupyter Notebook 6.1.4 is running at:  
[I 13:04:48.080 NotebookApp] http://localhost:8888/?token=d5facfe1ebd41a65d6db22c79d447b3f1dd0fae9522ceb0a  
[I 13:04:48.080 NotebookApp] or http://127.0.0.1:8888/?token=d5facfe1ebd41a65d6db22c79d447b3f1dd0fae9522ceb0a  
[I 13:04:48.081 NotebookApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).  
[C 13:04:48.351 NotebookApp]  
  
To access the notebook, open this file in a browser:  
file:///home/waqar/.local/share/jupyter/runtime/nbserver-9875-open.html  
Or copy and paste one of these URLs:  
http://localhost:8888/?token=d5facfe1ebd41a65d6db22c79d447b3f1dd0fae9522ceb0a  
or http://127.0.0.1:8888/?token=d5facfe1ebd41a65d6db22c79d447b3f1dd0fae9522ceb0a  
□
```



Anaconda pour Ubuntu (10/11)


- Cliquer sur New -> Python3 pour créer un Notebook.





Anaconda pour Ubuntu (11/11)


- C'est à cela qu'un Notebook ressemble





Implementer Python dans un Jupyter Notebook (1/2)

En lançant Jupyter Notebook, voici ce que vous verrez !



C'est là que nous écrivons
notre code, appelé cellule.
Vous pouvez en avoir autant
que vous le souhaitez.



Implementer Python dans un Jupyter Notebook (1/2)

- Écrivez votre code Python dans une cellule.
- Sélectionnez la cellule en cliquant dessus, puis cliquez sur le bouton Run pour exécuter le code.
- La sortie d'une cellule est produite juste en dessous de celle-ci.

https://

5PZz09


output

The screenshot shows the Jupyter Notebook interface. At the top, the title bar reads 'Jupyter Python_In_Jupyter' with a 'Last Checkpoint: 2 minutes ago (unsaved changes)' status and a 'Logout' button. Below the title bar is a menu bar with 'File', 'Edit', 'View', 'Insert', 'Cell', 'Kernel', 'Widgets', and 'Help'. A toolbar contains icons for saving, adding, undo, redo, and running. The 'Run' button is highlighted with a tooltip that says 'run cell, select below'. The main area displays a code cell with the input 'In [1]: print("Hello World")' and the output 'Hello World'. A red arrow points from the word 'output' to the output text. Below the first cell is an empty input cell 'In []: '.



Gestion des répertoires dans Jupyter Notebook– Windows (1/7)


- Pour ouvrir Jupyter Notebook dans un répertoire/dossier particulier dans Windows, copiez le chemin du répertoire.





Gestion des répertoires dans Jupyter Notebook– Windows (2/7)

- Dans votre barre de recherche, tapez Anaconda Prompt et lancez-la.
Anaconda Prompt est la CLI d'Anaconda.





Gestion des répertoires dans Jupyter Notebook– Windows (3/7)

- Anaconda Prompt s'ouvre sur votre lecteur C. Puisque nous voulons nous déplacer vers le lecteur D, nous tapons d : et appuyons sur entrée.


```
Anaconda Prompt (Anaconda3)
(base) C:\Users\22100199>d:
(base) D:\>
```

The screenshot shows a terminal window titled "Anaconda Prompt (Anaconda3)". The prompt is initially at the C: drive. The user enters "d:" and presses enter, moving the prompt to the D: drive. The window has standard Windows window controls (minimize, maximize, close) in the top right corner.



Gestion des répertoires dans Jupyter Notebook– Windows (4/7)

- Ensuite, pour passer au répertoire souhaité, on tape cd et on colle le chemin du répertoire.



```
Anaconda Prompt (Anaconda3)
(base) C:\Users\22100199>d:
(base) D:\>cd D:\DataScience_Projects
(base) D:\DataScience_Projects>
```



Gestion des répertoires dans Jupyter Notebook– Windows (5/7)

- Enfin, nous lançons Jupyter Notebook en tapant `jupyter notebook`.
- L'ouverture de Jupyter Notebook prend un certain temps.

```
Anaconda Prompt (Anaconda3) - jupyter notebook

(base) C:\Users\22100199>d:

(base) D:\>cd D:\DataScience_Projects


(base) D:\DataScience_Projects>jupyter notebook
[I 21:47:44.481 NotebookApp] The port 8888 is already in use, trying another port.
[I 21:47:44.481 NotebookApp] The port 8889 is already in use, trying another port.
[I 2021-09-30 21:47:45.068 LabApp] JupyterLab extension loaded from C:\Users\22100199\Anaconda3\lib\site-packages\jupyterlab
[I 2021-09-30 21:47:45.068 LabApp] JupyterLab application directory is C:\Users\22100199\Anaconda3\share\jupyter\lab
[I 21:47:45.068 NotebookApp] Serving notebooks from local directory: D:\DataScience_Projects
[I 21:47:45.068 NotebookApp] Jupyter Notebook 6.3.0 is running at:
[I 21:47:45.068 NotebookApp] http://localhost:8890/?token=14d64985db6992c640f1d073c32482fc04aa213dc8262852
[I 21:47:45.068 NotebookApp] or http://127.0.0.1:8890/?token=14d64985db6992c640f1d073c32482fc04aa213dc8262852
[I 21:47:45.068 NotebookApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).

_
```



Gestion des répertoires dans Jupyter Notebook– Windows (6/7)


- Une fois qu'il s'ouvre, nous pouvons soit ouvrir un notebook existant, soit en créer un nouveau.
- Dans ce cas, nous ouvrons le notebook existant nommé hello.ipynb.





Gestion des répertoires dans Jupyter Notebook– Windows (7/7)


- Voici à quoi ressemble hello.ipynb.





Gestion des répertoires dans Jupyter Notebook– Mac (1/3)

- Pour ouvrir Jupyter Notebook dans un répertoire/dossier particulier sur Mac, ouvrez ce répertoire dans le terminal.
- Tapez 'jupyter notebook' sans les guillemets et appuyez sur Entrée.




```
Last login: Fri Mar 27 23:32:59 on ttys000

The default interactive shell is now zsh.
To update your account to use zsh, please run `chsh -s /bin/zsh`.
For more details, please visit https://support.apple.com/kb/HT208050.
(base)      $ jupyter notebook
```



Gestion des répertoires dans Jupyter Notebook– Mac (2/3)


- Jupyter Notebook sera lancé dans votre navigateur.
- Vous pouvez créer un nouveau Notebook ou ouvrir un Notebook existant.
- Ouvrons ce fichier 'hello.ipynb'.





Gestion des répertoires dans Jupyter Notebook– Mac (3/3)


- Le fichier 'hello.ipynb' contient une simple instruction d'affichage.





Gestion des répertoires dans Jupyter Notebook– Ubuntu (1/4)

- Pour ouvrir Jupyter Notebook dans un répertoire/dossier particulier dans Ubuntu, allez dans ce répertoire, faites un clic droit et sélectionnez 'open in terminal'.
- Tapez 'jupyter notebook' sans les guillemets et appuyez sur Entrée.





Gestion des répertoires dans Jupyter Notebook– Ubuntu (2/4)

- Attendre un peu.


```
waqar@waqar-N750BU: ~/Documents/Python Lessons/Produ...
(base) waqar@waqar-N750BU:~/Documents/Python Lessons/Product/Chapter 1$ jupyter notebook
[I 12:37:48.012 NotebookApp] JupyterLab extension loaded from /home/waqar/anaconda3/lib/python3.8/site-packages/jupyterlab
[I 12:37:48.013 NotebookApp] JupyterLab application directory is /home/waqar/anaconda3/share/jupyter/lab
[I 12:37:48.017 NotebookApp] Serving notebooks from local directory: /home/waqar/Documents/Python Lessons/Product/Chapter 1
[I 12:37:48.017 NotebookApp] Jupyter Notebook 6.1.4 is running at:
[I 12:37:48.017 NotebookApp] http://localhost:8888/?token=5ba3e23ed05c480fe4a767b1dbb853ae0c163b31090a34c4
[I 12:37:48.017 NotebookApp] or http://127.0.0.1:8888/?token=5ba3e23ed05c480fe4a767b1dbb853ae0c163b31090a34c4
[I 12:37:48.017 NotebookApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 12:37:48.180 NotebookApp]

To access the notebook, open this file in a browser:
    file:///home/waqar/.local/share/jupyter/runtime/nbserver-2797-open.html
Or copy and paste one of these URLs:
    http://localhost:8888/?token=5ba3e23ed05c480fe4a767b1dbb853ae0c163b31090a34c4
    or http://127.0.0.1:8888/?token=5ba3e23ed05c480fe4a767b1dbb853ae0c163b31090a34c4
```



Gestion des répertoires dans Jupyter Notebook– Ubuntu (3/4)


- Jupyter Notebook sera lancé dans votre navigateur par défaut.
- Vous pouvez créer un nouveau Notebook ou ouvrir un Notebook existant.
- Ouvrons ce fichier 'hello.ipynb'.





Gestion des répertoires dans Jupyter Notebook– Ubuntu (4/4)

- Le fichier 'hello.ipynb' contient une simple instruction d'affichage.






Regression

La régression est une méthode statistique qui prédit une relation entre un résultat continu et la valeur d'une ou plusieurs variables d'entrée.

Types de Regression

- **Régression linéaire**


La relation entre les variables d'entrée et la variable de sortie est linéaire.



- **Régression linéaire simple** : une seule variable d'entrée est utilisée pour prédire une sortie.
- **Régression linéaire multiple** : plus d'une variable d'entrée est impliquée.

- **Régression non linéaire**

La sortie est modélisée par une fonction qui est une combinaison non linéaire des entrées.






Régression linéaire simple

Représentation des lignes

$$Y = mx + b$$



Equation de la ligne en termes de surface et de prix

$$\text{price} = m * \text{area} + b$$

Dependent variable

Independent variable



Régression linéaire simple

Régression linéaire simple en python

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
```

```
df = pd.read_csv("homeprices.csv")
df
```

	Area	Price
0	2600	550000
1	3000	565000
2	3200	610000
3	3600	680000
4	4000	725000

Import les bibliothèques importantes

Import linear model from sklearn library.

Import le fichier .csv de l'ensemble de données.




Régression linéaire simple

Régression linéaire simple en python

```
plt.xlabel('Area(sqr ft)')  
plt.ylabel('Price(US$)')  
plt.scatter(df.Area, df.Price, color = 'red', marker='+')
```

<matplotlib.collections.PathCollection at 0x2a2b538cee0>



Définissez les étiquettes x et y. L'étiquette x sera la surface et l'étiquette y sera le prix.



Régression linéaire simple

Régression linéaire simple en python

```
In [4]: reg = LinearRegression()  
reg.fit(df[['Area']], df.Price)
```

```
Out[4]: LinearRegression()
```

```
In [5]: reg.predict([[3300]])
```

```
Out[5]: array([628715.75342466])
```

```
In [6]: reg.intercept_
```

```
Out[6]: 180616.43835616432
```

```
In [7]: reg.coef_
```

```
Out[7]: array([135.78767123])
```


```
In [8]: 135.788 * 3300 + 180616.438
```

```
Out[8]: 628716.838
```





Regression linéaire multiple

Regression linéaire simple



Regression linéaire multiple





Regression linéaire multiple

Regression linéaire multiple en python

Ensemble de données

R&D Spend	Administration	Marketing Spend	State	Profit
165349.2	136897.8	471784.1	New York	192261.83
162597.7	151377.59	443898.53	California	191792.06
153441.51	101145.55	407934.54	Florida	191050.39
144372.41	118671.85	383199.62	New York	182901.99
142107.34	91391.77	366168.42	Florida	166187.94
131876.9	99814.71	362861.36	New York	156991.12
121615.16	117100.07	127716.02	California	156122.51



Regression linéaire multiple

Regression linéaire multiple en python

```
#import the libraries
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd

#reading the dataset
dataset = pd.read_csv('50_Startups.csv')
X = dataset.iloc[:, :-1].values
y = dataset.iloc[:, -1].values
dataset.head(5)
```

	R&D Spend	Administration	Marketing Spend	State	Profit
0	165349.20	136897.80	471784.10	New York	192261.83
1	162597.70	151377.59	443898.53	California	191792.06
2	153441.51	101145.55	407934.54	Florida	191050.39
3	144372.41	118671.85	383199.62	New York	182901.99
4	142107.34	91391.77	366168.42	Florida	166187.94



Regression linéaire multiple

Encodage des données catégorielles

X :

165349.2	136897.8	471784.1	New York
162597.7	151377.59	443898.53	California
153441.51	101145.55	407934.54	Florida
144372.41	118671.85	383199.62	New York
142107.34	91391.77	366168.42	Florida
131876.9	99814.71	362861.36	New York

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
ct = ColumnTransformer(transformers=[('encoder', OneHotEncoder(), [3])], remainder='passthrough')
X = np.array(ct.fit_transform(X))
```



Regression linéaire multiple

Encodage des données catégorielles
Après l'encodage, X:

0.0	0.0	1.0	165349.2	136897.8	471784.1
1.0	0.0	0.0	162597.7	151377.59	443898.53
0.0	1.0	0.0	153441.51	101145.55	407934.54
0.0	0.0	1.0	144372.41	118671.85	383199.62
0.0	1.0	0.0	142107.34	91391.77	366168.42
0.0	0.0	1.0	131876.9	99814.71	362861.36
1.0	0.0	0.0	134615.46	147198.87	127716.82



Regression linéaire multiple

Division de l'ensemble de données en un ensemble d'entraînement et un ensemble de test.

```
from sklearn.model_selection import train_test_split  
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2)
```



Regression linéaire multiple

Entraînement du modèle de régression linéaire multiple sur l'ensemble d'entraînement

```
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```



Regression linéaire multiple

Prévision des résultats du jeu de donnée d'essai

```
y_pred = regressor.predict(X_test)
```

```
df = pd.DataFrame({'Real Values':y_test, 'Predicted Values':y_pred})  
df
```

	Real Values	Predicted Values
0	65200.33	69622.870630
1	14681.40	52846.107901
2	49490.75	62780.406794
3	96712.80	94377.300765
4	97427.84	100871.598266
5	77798.83	77589.217308
6	97483.56	99644.979787
7	132602.65	151447.661176
8	103282.38	106415.733395
9	105008.31	116820.266911

**But, how to measure
how well our model
predicted?**



Évaluation du modèle pour la régression

Erreur absolue moyenne(EAM):

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Diagram illustrating the components of the Mean Absolute Error (EAM) formula:

- n : Nombre de valeurs
- y_i : Valeur réelle
- $\hat{y}_i$: Valeur prédite

Erreur quadratique moyenne (MSE) :

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Erreur quadratique moyenne racine (RMSE) :

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



Quiz Time

Laquelle des métriques d'évaluation suivantes peut être utilisée pour évaluer un modèle lors de la modélisation d'une variable de sortie continue ?

- A) AUC-ROC
- B) Précision
- C) Logloss
- D) Erreur quadratique moyenne



Quiz Time

Laquelle des métriques d'évaluation suivantes peut être utilisée pour évaluer un modèle lors de la modélisation d'une variable de sortie continue ?

- A) AUC-ROC
- B) Précision
- C) Logloss
- D) Erreur quadratique moyenne



Classification

Classification

La classification est un problème de modélisation prédictive dans l'apprentissage automatique où une étiquette de classe est prédite pour un échantillon donné de données d'entrée.

Application de la classification

- Filtrage des courriers indésirables
- Reconnaissance de la parole et de l'écriture manuscrite
- Biométrie
- Reconnaissance des empreintes digitales, etc.

Algorithmes de Classification

- Réseaux neuronaux
- Régression
- K- plus proche voisin



K-plus proche voisin(KNN)


K-Plus proche voisin (KNN)

L'algorithme K-plus proche voisin est une méthode de classification qui utilise un ensemble de points étiquetés pour apprendre à en identifier de nouveaux.

Algorithm de KNN

- Choisissez une valeur pour K.
- Déterminez la distance d'un point inconnu par rapport à tous les autres points.
- Maintenant, dans l'ensemble des données d'apprentissage, choisissez les K qui sont les plus proches du point de données inconnu.
- Prédisez maintenant la réponse du point de données inconnu.

$$Dis(x_1, x_2) = \sqrt{\sum_{i=0}^n (x_{1i} - x_{2i})^2}$$





K-plus proche voisin(KNN)

K- plus proche voisin(KNN)

- **Exemple**

Le classificateur KNN sera utilisé dans cet exemple pour classer l'image d'entrée en chat ou chien.





KNN Implementation

K-plus proche voisin(KNN) en python

Etape pour implementer KNN

- Prétraitement des données comme le filtrage
- Ajustement de KNN à l'ensemble d'entraînement
- Prédire les résultats du test.
- Tester la précision des résultats.

User ID	Gender	Age	EstimatedSalary	Purchased
15624510	Male	19	19000	0
15810944	Male	35	20000	0
15668575	Female	26	43000	0
15603246	Female	27	57000	0
15804002	Male	19	76000	0
15728773	Male	27	58000	0
15598044	Female	27	84000	0
15694829	Female	32	150000	1
15600575	Male	25	33000	0
15727311	Female	35	65000	0
15570769	Female	26	80000	0
15606274	Female	26	52000	0
15746139	Male	20	86000	0
15704987	Male	32	18000	0
15628972	Male	18	82000	0
15697686	Male	29	80000	0
15733883	Male	47	25000	1
15617482	Male	45	26000	1
15704583	Male	46	28000	1
15621083	Female	48	29000	1
15649487	Male	45	22000	1
15736760	Female	47	49000	1



KNN Implementation

K-plus proche voisin(KNN)en python

Implementation Etape 1

- Tout d'abord, nous allons importer les bibliothèques requises.

The image shows a Jupyter Notebook interface with the title "KNN_Binary_Classification (autosaved)". The top bar includes a "Logout" button and a "Python 3" selector. The menu bar contains "File", "Edit", "View", "Insert", "Cell", "Kernel", "Widgets", and "Help". Below the menu bar is a toolbar with icons for saving, adding cells, undo, redo, copy, paste, and running code. The main area displays a code cell with the following Python code:

```
In [1]: #Importing the libraries
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.metrics import confusion_matrix
```




KNN Implementation

K-plus proche voisin (KNN) en python

Implementation Etape 2

- Ensuite, nous allons importer les ensembles de données

```
# Importing the dataset  
dataset = pd.read_csv('user data.csv')  
X = dataset.iloc[:, 2:4].values  
y = dataset.iloc[:, 4].values
```

- Extraire les variables indépendantes et dépendantes - X & y



KNN Implementation

K-plus proche voisin (KNN) en python

Implementation Etape 3

- Divisez les données en deux ensembles, l'un pour les tests et l'autre pour l'entraînement.

```
In [3]: #Training and Testing Data (divide the data into two part)
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size= 0.25, random_s
```

- Importez sklearn pour le pré-traitement et mettez les caractéristiques à l'échelle.

```
In [4]: from sklearn.preprocessing import StandardScaler
sc_X = StandardScaler()
X_train = sc_X.fit_transform(X_train)
X_test = sc_X.fit_transform(X_test)
```



KNN Implementation

K-plus proche voisin(KNN)en python

Données non échelonnées

```
print(X_train)
```

```
[[ 44 39000]
 [ 32 120000]
 [ 38 50000]
 [ 32 135000]
 [ 52 21000]
 [ 53 104000]
 [ 39 42000]
 [ 38 61000]
 [ 36 50000]
 [ 36 63000]
 [ 35 25000]
 [ 35 50000]
 [ 42 73000]
 [ 17 100000]
```

Données échelonnées

```
print(X_train)
```

```
[[ 0.58164944 -0.88670699]
 [-0.60673761  1.46173768]
 [-0.01254409 -0.5677824 ]
 [-0.60673761  1.89663484]
 [ 1.37390747 -1.40858358]
 [ 1.47293972  0.99784738]
 [ 0.08648817 -0.79972756]
 [-0.01254409 -0.24885782]
 [-0.21060859 -0.5677824 ]
 [-0.21060859 -0.19087153]
 [-0.30964085 -1.29261101]
 [-0.30964085 -0.5677824 ]
 [ 0.38358493  0.09905991]
 [ 0.8787462  -0.59677555]
 [ 2.06713324 -1.17663843]
 [ 1.07681071 -0.13288524]
```



KNN Implementation

K-plus proche voisin(KNN)en python

Implementation Etape 4

- Importez le classifieur KNN de la bibliothèque sklearn

```
In [8]: from sklearn.neighbors import KNeighborsClassifier  
        classifier=KNeighborsClassifier(n_neighbors=5, metric="minkowski", p=2)  
        classifier.fit(X_train,y_train)  
  
Out[8]: KNeighborsClassifier()
```

Définir les différents paramètres :

- n_neighbors
- metric='minkowski'.
- p=2.



KNN Implementation

K-plus proche voisin(KNN) en python

Prévision des résultats et matrice de confusion

- Nous allons maintenant prédire les résultats en utilisant la méthode predict().
- Obtenir la matrice de confusion en utilisant les valeurs y_pred, y_test

```
y_pred = classifier.predict(X_test)

# Making the Confusion Matrix
cm = confusion_matrix(y_pred, y_test)
print(cm)
```

```
[[64  3]
 [ 4 29]]
```

Predictions corrects= $64+29 = 93$

Prediction incorrects= $3+4 = 7$



Quiz Time

La classification est...

- A. L'apprentissage non supervisé
- B. L'apprentissage par renforcement
- C. Apprentissage supervisé
- D. Aucun



Quiz Time

La classification est...

- A. L'apprentissage non supervisé
- B. L'apprentissage par renforcement
- C. Apprentissage supervisé
- D. Aucun




Arbre de décision

Qu'est ce qu'un arbre de décision

Les arbres de décision sont un type d'apprentissage automatique supervisé dans lequel les données sont continuellement segmentées en fonction d'un paramètre.

Algorithme d'apprentissage de l'arbre de décision

- Choisissez une caractéristique dans l'ensemble de données donné.
- Déterminez l'importance de la caractéristique dans la segmentation des données.
- La segmentation des données dépend du meilleur attribut.
- Répétez maintenant les étapes précédentes.





Arbre de décision

Entropie

Il s'agit de la mesure de la quantité d'incertitude ou d'aléatoire dans les données.

$$H(S) = \sum_{x \in X} p(x) \log_2 \frac{1}{p(x)}$$

P(x) is a probability
function of the event x to
take place

Valeur la plus basse : 0 (pas de caractère aléatoire)
Valeur la plus élevée : 1 (caractère aléatoire élevé)



Implémentation d'un arbre de décision

Construire un arbre de decision en python

Ensemble de donnée

In [12]: `data.head(10)`

Out[12]:


	company	job	degree	salary_more_than_100k
0	company	job	degree	salary_more_than_100k
1	google	sale exective	bachelaors	0
2	google	sale exective	masters	0
3	google	business manager	bachelaors	1
4	google	business manager	masters	1
5	google	computer programmer	bachelaors	0
6	google	computer programmer	masters	1
7	abc pharma	sale exective	masters	0
8	abc pharma	computer programmer	bachelaors	0
9	abc pharma	business manager	bachelaors	0



Implémentation d'un arbre décisionnel

Construire un arbre décisionnel en python

Arbre décisionnel





Implémentation d'un arbre décisionnel

Construire un arbre décisionnel en Python

Implementation Etape 1

- Importer les bibliothèques nécessaires

The screenshot shows a Jupyter Notebook window titled "Decision_tree (unsaved changes)". The interface includes a top bar with the Jupyter logo, a "Logout" button, and a menu bar with options: File, Edit, View, Insert, Cell, Kernel, Widgets, and Help. Below the menu bar is a toolbar with icons for saving, adding cells, undo, redo, and running code. The main area displays a code cell labeled "In [1]:" containing the following Python code:

```
# Load libraries
import pandas as pd
from sklearn.tree import DecisionTreeClassifier # Import Decision Tree Classifier
from sklearn.model_selection import train_test_split # Import train_test_split function
from sklearn import metrics #Import scikit-learn metrics module for accuracy calculation
```



Implémentation d'un arbre de décision

Construire un arbre de décision en python

Implementation Etape 2

- Définir les variables de données et importer le fichier de données

```
In [2]: #Working with the dataset here

col_names = ['company', 'job', 'degree', 'salary_more_than_100k']# Load dataset
data = pd.read_csv("salaries.csv", header=None, names=col_names)
```



Implémenter un arbre de décision

Constuire un arbre de decision en python

Implementation Etape 3

- Divisez les données en caractéristiques (Entrées - X) et en variable cible (sortie y)

```
In [19]: #Split the dataset in features and target variable
feature_cols = ['company','job','degree']
X = data[feature_cols]
y = data['salary_more_than_100k']
```

- Variable cible => Salary_more_than100k
- Définition des caractéristiques pour le salaire => entreprise, emploi, diplôme



Implémentation d'un arbre de décision

Construire un arbre de decision en Python

Implementation Etape 4

- Encoder les caractéristiques catégorielles en valeurs numériques
- Utiliser un codeur ordinal

```
In [4]: # Import label encoder
from sklearn import preprocessing
# Label_encoder object knows how to understand word labels.
label_encoder = preprocessing.LabelEncoder()
# Encode labels in column
data['company'] = label_encoder.fit_transform(data['company'])
data['job'] = label_encoder.fit_transform(data['job'])
data['degree'] = label_encoder.fit_transform(data['degree'])
print(data.head())
```

	company	job	degree	salary_more_than_100k
0	1	2	1	salary_more_than_100k
1	3	3	0	0
2	3	3	2	0
3	3	0	0	1
4	3	0	2	1



Implémentation d'un arbre de décision

Construire un arbre de decision en python

```
print(X)
```

	company	job	degree
0	1	2	1
1	3	3	0
2	3	3	2
3	3	0	0
4	3	0	2
5	3	1	0
6	3	1	2
7	0	3	2
8	0	1	0
9	0	0	0
10	0	0	2
11	2	3	0
12	2	3	2
13	2	0	0
14	2	0	2
15	2	1	0
16	2	1	2

```
In [20]: print(y)
```

	salary_more_than_100k
0	
1	0
2	0
3	1
4	1
5	0
6	1
7	0
8	0
9	0
10	1
11	1
12	1
13	1
14	1
15	1
16	1

Name: salary_more_than_100k, dtype: object



Implémentation d'un arbre de décision

Construction d'un arbre de décision en python

Implementation Etape 5

- *Divisez les données en ensembles de formation et de test*

```
In [7]: X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=100)
```



Decision Tree Implementation

Contruction d'un arbre de decision en python

Implementation Etape 6

- Création d'un arbre de décision
- Utiliser l'entropie pour entraîner le modèle

```
In [24]: # Create Decision Tree classifier object using entropy
clf_entropy = DecisionTreeClassifier(criterion="entropy", max_depth=3)

# Train Decision Tree Classifier
clf_entropy = clf_entropy.fit(X_train,y_train)
```

- Prédire les résultats et déterminer la précision du modèle.

```
In [8]: # Create Decision Tree classifier object using entropy
clf_entropy = DecisionTreeClassifier(criterion="entropy", max_depth=8)

# Train Decision Tree Classifier
clf_entropy = clf_entropy.fit(X_train,y_train)

#Predict the response for test dataset
y_pred = clf_entropy.predict(X_test)

print("Accuracy:", metrics.accuracy_score(y_test,y_pred))
```

Accuracy: 0.75



Quiz Time

Les arbres de décision peuvent être utilisés pour les tâches de classification.

- a) Vrai
- b) Faux



Quiz Time

Les arbres de décision peuvent être utilisés pour les tâches de classification.

- a) Vrai
- b) Faux



Logistic Regression

Qu'est-ce que la régression logistique ?


Le modèle logistique est utilisé pour prédire la probabilité d'une classe ou d'une occurrence spécifique.

Conditions d'utilisation de la régression logistique

- Si l'information est binaire.
- Si vous avez besoin de résultats probabilistes.
- Lorsqu'une limite de décision linéaire est requise.

Applications

- Pour prévoir la survie des patients blessés dans le corps médical.
- Estimer la probabilité qu'une personne subisse une crise cardiaque.
- Prédire la probabilité d'échec d'une procédure ou d'un produit.
- Prédire la possibilité pour un propriétaire de faire défaut à son prêteur.





Mise en œuvre de la régression logistique

Régression logistique en python

- **Étapes de la mise en œuvre de la régression logistique**
 - Prétraitement des données comme le filtrage
 - Ajustement de KNN à l'ensemble de formation.
 - Prédire les résultats du test.
 - Tester la précision des résultats.

User ID	Gender	Age	EstimatedSalary	Purchased
15624510	Male	19	19000	0
15810944	Male	35	20000	0
15668575	Female	26	43000	0
15603246	Female	27	57000	0
15804002	Male	19	76000	0
15728773	Male	27	58000	0
15598044	Female	27	84000	0
15694829	Female	32	150000	1
15600575	Male	25	33000	0
15727311	Female	35	65000	0
15570769	Female	26	80000	0
15606274	Female	26	52000	0
15746139	Male	20	86000	0
15704987	Male	32	18000	0
15628972	Male	18	82000	0
15697686	Male	29	80000	0
15733883	Male	47	25000	1
15617482	Male	45	26000	1
15704583	Male	46	28000	1
15621083	Female	48	29000	1
15649487	Male	45	22000	1
15736760	Female	47	49000	1



Mise en œuvre de la régression logistique

Régression logistique en python

Étape de mise en œuvre 1

- Tout d'abord, nous allons importer les bibliothèques importantes.

The image shows a Jupyter Notebook interface. The title bar reads "jupyter logistic_regression_Binary_Classification (unsaved changes)". The menu bar includes "File", "Edit", "View", "Insert", "Cell", "Kernel", "Widgets", and "Help". On the right, there is a "Logout" button and a "Not Trusted" warning. Below the menu bar is a toolbar with icons for saving, adding cells, undo, redo, and running code. The main area contains a code cell with the following Python code:

```
In [1]: #Importing the Libraries
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.metrics import confusion_matrix
```



Mise en œuvre de la régression logistique

Régression logistique en python

Étape de mise en œuvre 2

- Nous allons importer les ensembles de données donnés.
- Extraire les variables indépendantes et dépendantes.

```
In [3]: # Importing the dataset
dataset = pd.read_csv('user data.csv')
X = dataset.iloc[:, [2,4]].values
y = dataset.iloc[:, 4].values
```




Mise en œuvre de la régression logistique

Régression logistique en python

Étape de mise en œuvre 3

- Divisez les données en ensembles de données de test et de formation.
- Importez sklearn pour le prétraitement et mettez à l'échelle les caractéristiques.

```
In [4]: #Training and Testing Data (divide the data into two part)
        from sklearn.model_selection import train_test_split
        X_train, X_test, y_train, y_test = train_test_split(X,y,test_size= 0.25, random_state=0)
```



Mise en œuvre de la régression logistique

Régression logistique en python

Étape de mise en œuvre 3

- Importez sklearn pour le pré-traitement et mettez à l'échelle les caractéristiques.

```
In [5]: from sklearn.preprocessing import StandardScaler  
sc_X = StandardScaler()  
X_train = sc_X.fit_transform(X_train)  
X_test = sc_X.fit_transform(X_test)
```



Mise en œuvre de la régression logistique

Régression logistique en python

Données mises à l'échelle

In [11]: `print(X)`

```
[[19  0]
 [35  0]
 [26  0]
 [27  0]
 [19  0]
 [27  0]
 [27  0]
 [32  1]
 [25  0]
 [35  0]
 [26  0]
 [26  0]
 [20  0]
 [32  0]
 [18  0]
 [29  0]
 [47  1]
 [45  1]
 [46  1]
 [49  1]]
```

In [9]: `print(X_train)`

```
[[ 0.58164944 -0.76635604]
 [-0.60673761  1.30487651]
 [-0.01254409 -0.76635604]
 [-0.60673761  1.30487651]
 [ 1.37390747  1.30487651]
 [ 1.47293972  1.30487651]
 [ 0.08648817 -0.76635604]
 [-0.01254409 -0.76635604]
 [-0.21060859 -0.76635604]
 [-0.21060859 -0.76635604]
 [-0.30964085 -0.76635604]
 [-0.30964085 -0.76635604]
 [ 0.38358493  1.30487651]
 [ 0.8787462   1.30487651]
 [ 2.06713324  1.30487651]
 [ 1.07681071 -0.76635604]
 [ 0.68068169  1.30487651]
 [-0.70576986 -0.76635604]
 [ 0.77971394 -0.76635604]
 [ 0.8787462   1.30487651]]
```



Mise en œuvre de la régression logistique

Régression logistique en python

Étape de mise en œuvre 4

- **Ajustement du classificateur de régression logistique aux données d'entraînement**
- Importez sklearn et obtenez notre classificateur - Régression logistique

```
In [12]: from sklearn.linear_model import LogisticRegression  
         classifier=LogisticRegression(random_state=0)  
         classifier.fit(X_train,y_train)
```

```
Out[12]: LogisticRegression(random_state=0)
```



Régression logistique vs. régression linéaire

Régression logistique

- Nous estimons les valeurs des variables catégorielles en utilisant la régression logistique.
- Nous découvrons la courbe en S dans la régression logistique et l'utilisons pour catégoriser les échantillons.
- Il n'est pas nécessaire d'avoir un lien linéaire entre les variables dépendantes et indépendantes dans la régression logistique.
- Il ne doit pas y avoir de colinéarité entre les variables indépendantes dans la régression logistique.

Régression linéaire

- Nous estimons le résultat des variables continues en utilisant la régression linéaire.
- Dans la régression linéaire, nous recherchons la ligne la mieux ajustée, qui nous permet de prédire le résultat avec facilité.
- Il est nécessaire que le lien entre les variables dépendantes et indépendantes soit linéaire.
- Il existe une possibilité de colinéarité entre les facteurs indépendants dans la régression linéaire.



Quiz Time

La régression logistique est-elle principalement utilisée pour la régression ?

- A) VRAI
- B) FAUX



Quiz Time

La régression logistique est-elle principalement utilisée pour la régression ?

A) VRAI

B) FAUX

Solution : B

La régression logistique est un algorithme de classification, à ne pas confondre avec le nom de régression.




Clustering

Qu'est ce que le Clustering?

Le Clustering est un apprentissage non supervisé ; il s'agit d'un processus de partitionnement d'un ensemble de données en sous-classes significatives.

Applications du Clustering

- Reconnaissance des formes
- Analyse des données spatiales
- Traitement d'images
- Classification de documents
- Identification d'entités similaires
- Recherche de modèles de comportement météorologique





Clustering

Pourquoi avons-nous besoin du clustering ?

Le Clustering peut être utilisée pour les tâches suivantes :

- Analyser les données de la recherche
- Créer un résumé
- Détecter le bruit
- Détection des doublons
- Procédures de prétraitement

Algorithmes de clustering

- Classification K-Means
- Classification hiérarchique
- Clustering basé sur la densité



Clustering


K-Means Clustering

Il s'agit d'un algorithme itératif qui divise l'ensemble de données non étiquetées en k groupes différents de manière à ce que chaque ensemble de données n'appartienne qu'à un seul groupe ayant des propriétés similaires..

Algorithmes de K-Clustering

Voici un algorithme de clustering K-Means :

- Le clustering par partition
- Sans aucune structure interne de cluster, K-Means divise les données en groupes non chevauchants.
- Au sein d'un cluster, les exemples sont très similaires.
- Les différents clusters ont des exemples très différents.





Clustering

Determination de K dans le K-means clustering

La performance de l'algorithme de clustering K-means dépend de l'efficacité des clusters qu'il forme. Mais choisir le nombre optimal de clusters est une tâche importante.

Méthode du coude

Cette méthode utilise le concept de la valeur WCSS. WCSS signifie Within Cluster Sum of Squares, qui définit les variations totales au sein d'une grappe. La formule pour calculer la valeur de WCSS.


$$WCSS = \sum_{P_i \text{ in Cluster1}} \text{distance}(P_i, C_1)^2 + \sum_{P_i \text{ in Cluster2}} \text{distance}(P_i, C_2)^2 + \sum_{P_i \text{ in Cluster3}} \text{distance}(P_i, C_3)^2$$



Clustering

Étapes de la méthode du coude

- Il exécute le clustering K-means sur un jeu de données donné pour différentes valeurs de K (de 1 à 10).
- Pour chaque valeur de K, calcule la valeur WCSS.
- Trace une courbe entre les valeurs WCSS calculées et le nombre de clusters K.
- Le point de courbure ou un point du tracé ressemble à un bras, alors ce point est considéré comme la meilleur






La méthode du coude

```
In [66]: # Finding the optimal number of clusters using elbow method
from sklearn.cluster import KMeans
wcss_list = [] # Initializing the list for the values of WCSS

# 10 iterations
for i in range(1,11):
    kmeans=KMeans(n_clusters=i, init='k-means++',random_state =42)
    kmeans.fit(X)
    wcss_list.append(kmeans.inertia_)

plt.plot(range(1,11),wcss_list)
plt.title("the elbow method")
plt.xlabel("numbr of cluster")
plt.ylabel("wcss_list")
plt.show()
```





Clustering

Qu'est-ce que le clustering hiérarchique ?

Il s'agit d'un algorithme qui regroupe les objets similaires en groupes appelés clusters. Le point final est un ensemble de clusters, où chaque cluster est distinct de tous les autres, et où les objets au sein de chaque cluster sont globalement similaires les uns aux autres.

Types de clustering hiérarchique

Il existe deux types de clustering hiérarchique :

- Le clustering divisé est une approche de haut en bas dans laquelle les observations partent d'un grand cluster et se divisent en plus petits.
- Le clustering agglomératif est une approche de bas en haut dans laquelle les observations partent de plusieurs clusters et sont fusionnées en un seul cluster à la fin.





Clustering

Qu'est-ce que le clustering basé sur la densité ?


Le clustering basé sur la densité localise les régions de haute densité et sépare les valeurs aberrantes. Ainsi, les régions de haute densité sont séparées des régions de faible densité.

Qu'est-ce que DBSCAN?

L'attribut le plus puissant de l'algorithme DBSCAN est qu'il peut trouver n'importe quel groupe de forme arbitraire sans être affecté par le bruit.

Avantages

- Il peut découvrir des clusters de forme arbitraire.
- Trouver un cluster entouré de différents clusters.
- Robuste vis-à-vis de la détection du bruit.





Clustering

K-means clustering en python

Étape de mise en œuvre 1

- *Importez le jeu de données requis*

```
In [18]: %matplotlib inline
         from copy import deepcopy
         import numpy as np
         import pandas as pd
         from matplotlib import pyplot as plt
         plt.rcParams['figure.figsize'] = (16, 9)
         plt.style.use('ggplot')
```




Clustering

K-means clustering en python

Étape de mise en œuvre 2

- Importez le jeu de données requis

```
In [19]: # Importing the dataset
data = pd.read_csv('mallCustomerData.txt', sep=",")
print(data.shape)
data.head(10)
```

(200, 5)

Out[19]:

	CustomerID	Gender	Age	Annual Income (k\$)	Spending Score (1-100)
0	1	Male	19	15	39
1	2	Male	21	15	81
2	3	Female	20	16	6
3	4	Female	23	16	77
4	5	Female	31	17	40
5	6	Female	22	17	76
6	7	Female	35	18	6
7	8	Female	23	18	94
8	9	Male	64	19	3
9	10	Female	30	19	72



Clustering

K-means clustering en python

Etape de mise en œuvre 3

- HotEncoding des valeurs de Genre

```
In [5]: print(data['Gender'].value_counts())
```

```
Female    112
Male       88
Name: Gender, dtype: int64
```

```
In [6]: data = pd.get_dummies(data, columns=['Gender'])
print(data)
```

	CustomerID	Age	Annual Income (k\$)	Spending Score (1-100)	\
0	1	19	15	39	
1	2	21	15	81	
2	3	20	16	6	
3	4	23	16	77	
4	5	31	17	40	
..	...	...	...	...	...
195	196	35	120	79	
196	197	45	126	28	
197	198	32	126	74	
198	199	32	137	18	
199	200	30	137	83	

	Gender_Female	Gender_Male
0	0	1
1	0	1
2	1	0
3	1	0
4	1	0
..	...	...
195	1	0
196	1	0
197	0	1
198	0	1
199	0	1

```
[200 rows x 6 columns]
```



Clustering

K-means clustering in python

Étape de mise en œuvre 4

- Visualiser le jeu de données


```
In [20]: # Getting the values and plotting it
f1 = data['Annual Income (k$)'].values
f2 = data['Spending Score (1-100)'].values

for key in data.keys():
    print(key)

X = np.array(list(zip(f1, f2)))
#X=[[1, 1], [1, 2], [3, 3],[4,4]]
plt.scatter(f1, f2, c='black', s=20)
```

```
CustomerID
Gender
Age
Annual Income (k$)
Spending Score (1-100)
```

```
Out[20]: <matplotlib.collections.PathCollection at 0x1460b208be0>
```





Clustering

K-means clustering en python

Étape de mise en œuvre 5

- Définition du classificateur
- Ajuster le kmeans
- Afficher les valeurs des coordonnées des clusters

```
In [50]: from sklearn.cluster import KMeans

# Number of clusters
kmeans = KMeans(n_clusters=3)
# Fitting the input data
kmeans = kmeans.fit(X)
# Getting the cluster labels
labels = kmeans.predict(X)
# Centroid values
C = kmeans.cluster_centers_
```

```
In [57]: # Values of the clusters
print(C)

[[-2.59662966  8.17293022 -3.18861476]
 [ 9.90577958 -1.78901987  4.83348761]
 [-2.67717112 -0.81623897 -7.81162806]
 [-5.19053091  0.683535   -2.16596538]]
```



Clustering


K-means clustering in python

Etape de mise en œuvre 6

- Un graphique 3D de notre jeu de données

```
In [41]: fig = plt.figure()
ax = Axes3D(fig)
ax.scatter(X[:, 0], X[:, 1], X[:, 2])

Out[41]: <mpl_toolkits.mplot3d.art3d.Path3DCollection at 0x1460cc20cd0>
```





Clustering


K-means clustering en python

Étape de mise en œuvre 7 - Tracé 3D de la prédiction Clusters

```
In [57]: # Values of the clusters  
print(C)
```

```
[[-2.59662966  8.17293022 -3.18861476]  
 [ 9.90577958 -1.78901987  4.83348761]  
 [-2.67717112 -0.81623897 -7.81162806]  
 [-5.19053091  0.683535  -2.16596538]]
```

```
fig = plt.figure()  
ax = Axes3D(fig)  
ax.scatter(X[:, 0], X[:, 1], X[:, 2], c='y')  
ax.scatter(C[:, 0], C[:, 1], C[:, 2], marker='*', c='#050505', s=1000)  
  
<mpl_toolkits.mplot3d.art3d.Path3DCollection at 0x1498114b5b0>
```





Clustering

K-means clustering en python

Étape de mise en œuvre 7

Vérification du numéro de grappe des valeurs prédites

```
In [67]: # Initializing KMeans
kmeans = KMeans(n_clusters=4)
# Fitting with inputs
kmeans = kmeans.fit(X)
# Predicting the clusters
labels = kmeans.predict(X)
# Getting the cluster centers
C = kmeans.cluster_centers_
print(labels)
```

```
print(labels)
```

```
[3 1 3 0 2 1 1 1 2 2 2 1 3 0 2 2 2 1 3 0 3 0 1 3 0 3 0 0 1 0 2 3 3 2 2 1 0
 2 2 3 0 1 3 0 3 3 0 1 3 2 0 2 0 0 2 0 2 1 1 2 1 3 0 1 2 1 2 0 0 3 3 2 0 0
 2 3 0 2 0 3 0 3 3 0 3 3 0 2 3 1 1 1 3 0 2 2 3 3 0 3 1 1 0 1 3 1 1 0 3 2 1
 1 1 0 2 1 0 0 3 2 0 2 1 0 3 2 0 0 3 1 3 3 1 0 2 2 2 0 2 1 1 3 2 3 1 3 0 3
 0 2 1 2 0 2 2 1 2 0 1 1 0 2 0 0 3 2 2 2 2 3 3 2 3 2 3 2 1 2 2 2 3 1 3 1 3
 3 2 3 1 1 0 3 0 2 1 0 2 0 2 1 3 2 1 2 1 3 3 0 3 1 1 2 3 3 0 0 3 1 2 0 2 2
 2 0 3 0 3 2 0 1 0 0 2 0 2 0 3 1 2 2 0 0 3 3 0 1 1 3 0 0 3 3 2 0 0 0 0 1
 1 2 1 3 3 3 2 2 0 1 0 2 0 0 0 1 3 3 3 0 2 1 3 3 1 0 2 3 3 1 1 1 0 0 1 0 0
 2 2 0 3 3 0 1 3 1 2 0 3 3 3 2 1 3 0 2 3 3 3 1 0 1 2 1 0 2 3 0 0 0 2 3 0 3
 0 1 1 2 1 3 1 2 1 2 2 0 1 1 3 3 2 3 2 0 3 3 2 1 1 1 2 0 1 0 1 1 2 1 1 0 2
 3 3 3 2 3 0 1 0 1 1 2 2 3 3 2 3 1 0 0 1 0 0 0 3 1 2 1 3 3 2 0 0 1 3 1 1 2
 1 1 2 3 1 3 2 0 3 3 0 2 1 3 3 3 1 2 3 1 3 2 2 3 2 0 2 0 1 2 1 3 1 0 1 3 3
 2 3 2 0 1 2 2 1 3 0 0 2 2 2 1 0 3 2 1 2 0 1 1 0 3 1 1 3 0 1 2 1 0 2 1 0 1
 3 3 2 1 0 0 3 2 3 3 1 2 3 0 0 0 1 2 0 2 3 3 2 3 1 1 0 1 1 0 0 0 1 3 2 0 1
 1 2 1 3 2 2 2 2 0 0 2 1 3 0 3 0 1 1 2 2 2 0 0 2 2 2 1 1 3 2 3 1 0 0 3 2 3
 1 2 0 1 3 3 2 2 0 2 2 3 2 0 0 0 3 3 1 1 1 2 0 2 1 2 1 3 3 3 0 2 1 2 3 3 3
 0 1 0 0 3 3 3 0 1 1 1 3 2 3 2 3 2 0 3 1 2 0 3 2 0 3 0 0 0 1 1 2 2 0 1 2 1
 3 1 0 0 0 2 2 0 1 3 2 1 1 1 0 3 3 1 1 1 0 0 0 1 0 2 1 1 2 2 1 2 3 3 1 0 3
 0 2 1 1 1 0 1 0 3 2 1 3 2 2 0 0 3 2 3 3 2 2 0 3 1 1 1 0 0 2 3 0 0 3 0 2 1
 3 1 2 2 2 1 3 2 2 2 0 1 2 3 1 1 1 2 1 2 0 3 3 3 1 3 1 0 0 3 1 3 0 0 3 3 3
 3 2 0 0 2 3 1 2 1 2 1 2 2 1 2 0 0 1 0 2 2 1 3 0 1 0 1 3 2 3 0 1 1 2 3 2 2
 3 1 3 1 0 3 3 0 3 3 2 0 0 0 3 0 1 1 0 1 1 2 2]
```



Quiz Time

Lequel des éléments suivants est requis par le clustering K-means ?

- A) une métrique de distance définie
- B) nombre de clusters
- C) une estimation initiale des centres des clusters
- D) toutes les réponses mentionnées



Quiz Time

Lequel des éléments suivants est requis par le clustering K-means ?

- A) une métrique de distance définie
- B) nombre de clusters
- C) une estimation initiale des centres des clusters
- D) toutes les réponses mentionnées

Réponse : D

Explication : le clustering K-means suit une approche de partitionnement.



Systeme de recommandation

Qu'est-ce qu'un système de recommandation ?

Les systèmes de recommandation sont des algorithmes visant à suggérer des éléments pertinents aux utilisateurs, par exemple des films à regarder, des textes à lire, des produits à acheter ou tout autre élément dépendant des secteurs d'activité.

Applications

Les applications des systèmes de recommandation comprennent les films, la musique, les livres, les sites web, les documents, les programmes de télévision, etc.

Avantages

- Augmentez l'engagement des clients.
- Augmentez la satisfaction des clients en leur fournissant un contenu pertinent.
- Réduire le temps de recherche de contenu.






Systeme de recommandation

Filtrage collaboratif Systeme de recommandation

La méthode de filtrage collaboratif permet de prédire les intérêts d'un utilisateur pour un produit en recueillant des informations sur les préférences de nombreux autres utilisateurs.





Système de recommandation

Système de recommandation en python

Étape de mise en œuvre 1

- Importer les bibliothèques
- Obtenir les jeux de données

```
In [1]: import numpy as np
import pandas as pd

#for visualization
import matplotlib.pyplot as plt
import seaborn as sns
sns.set_style('white')
%matplotlib inline
```

```
In [4]: movie_titles = pd.read_csv("Movie_Id_Titles")
movie_titles.head()
```

Out[4]:

	item_id	title
0	1	Toy Story (1995)
1	2	GoldenEye (1995)
2	3	Four Rooms (1995)
3	4	Get Shorty (1995)
4	5	Copycat (1995)

```
In [2]: column_names = ['user_id', 'item_id', 'rating', 'timestamp']
df = pd.read_csv('u.data', sep='\t', names=column_names)
```

```
In [3]: df.head()
```

Out[3]:

	user_id	item_id	rating	timestamp
0	0	50	5	881250949
1	0	172	5	881250949
2	0	133	1	881250949
3	196	242	3	881250949
4	186	302	3	891717742



Système de recommandation

Système de recommandation en python

Étape de mise en œuvre 2

- Fusionner les deux tables
- En utilisant `item_id`

```
In [5]: df = pd.merge(df, movie_titles, on='item_id')
df.head()
```

Out[5]:

	user_id	item_id	rating	timestamp	title
0	0	50	5	881250949	Star Wars (1977)
1	290	50	5	880473582	Star Wars (1977)
2	79	50	4	891271545	Star Wars (1977)
3	2	50	5	888552084	Star Wars (1977)
4	8	50	5	879362124	Star Wars (1977)



Système de recommandation

Système de recommandation en python

Mise en oeuvre étape 3

- Trier les lignes par groupe de
- Titre, et classement

Trouver :-

- Nombre
- Moyenne

```
In [8]: df.groupby('title')['rating'].count().sort_values(ascending=False).head()
```

```
Out[8]: title
Star Wars (1977)          584
Contact (1997)            509
Fargo (1996)             508
Return of the Jedi (1983) 507
Liar Liar (1997)          485
Name: rating, dtype: int64
```

```
In [7]: df.groupby('title')['rating'].mean().sort_values(ascending=False).head()
```

```
Out[7]: title
They Made Me a Criminal (1939)    5.0
Marlene Dietrich: Shadow and Light (1996)  5.0
Saint of Fort Washington, The (1993)  5.0
Someone Else's America (1995)  5.0
Star Kid (1997)  5.0
Name: rating, dtype: float64
```



Système de recommandation

Système de recommandation en python

Mise en œuvre de l'étape 4

- Trier les lignes par groupe de titres et d'évaluation.

```
In [9]: ratings = pd.DataFrame(df.groupby('title')['rating'].mean())  
ratings.head()
```

```
Out[9]:
```

	rating
title	
'Til There Was You (1997)	2.333333
1-900 (1994)	2.600000
101 Dalmatians (1996)	2.908257
12 Angry Men (1957)	4.344000
187 (1997)	3.024390

```
In [10]: ratings['num of ratings'] = pd.DataFrame(df.groupby('title')['rating'].count())  
ratings.head()
```

```
Out[10]:
```

	rating	num of ratings
title		
'Til There Was You (1997)	2.333333	9
1-900 (1994)	2.600000	5
101 Dalmatians (1996)	2.908257	109
12 Angry Men (1957)	4.344000	125
187 (1997)	3.024390	41

- Créez une nouvelle colonne
Et mettre le nombre d'évaluations



Système de recommandation


Système de recommandation en python

Mise en œuvre de l'étape 5

- On trace la colonne nouvellement créée

```
In [11]: plt.figure(figsize=(10,4))  
ratings['num of ratings'].hist(bins=70)
```

```
Out[11]: <AxesSubplot:>
```





Système de recommandation


Système de recommandation en python

Mise en œuvre étape 6

- Histogramme des évaluations

```
In [12]: plt.figure(figsize=(10,4))  
ratings['rating'].hist(bins=70)
```

```
Out[12]: <AxesSubplot:>
```





Système de recommandation


Système de recommandation en python

Mise en œuvre de l'étape 7

- Un graphique combiné des évaluations et du nombre d'évaluations

```
In [13]: sns.jointplot(x='rating',y='num of ratings',data=ratings,alpha=0.5)
```

```
Out[13]: <seaborn.axisgrid.JointGrid at 0x1d21cb69d00>
```





Système de recommandation

Système de recommandation en python

Étape de mise en œuvre 8

Importation des films du jeu de données et prétraitement de celui-ci

```
In [14]: moviemat = df.pivot_table(index='user_id',columns='title',values='rating')
moviemat.head()
```

Out[14]:

	'Til There Was You (1997)	1-900 (1994)	101 Dalmatians (1996)	12 Angry Men (1957)	187 (1997)	2 Days in the Valley (1996)	20,000 Leagues Under the Sea (1954)	2001: A Space Odyssey (1968)	3 Ninjas: High Noon At Mega Mountain (1998)	39 Steps, The (1935)	...	Yankee Zulu (1994)	Year of the Horse (1997)	You So Crazy (1994)	Young Frankenstein (1974)	Young Guns (1988)	Young Guns II (1990)	Y Poisc Handl The (
user_id																		
0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	NaN	NaN	2.0	5.0	NaN	NaN	3.0	4.0	NaN	NaN	...	NaN	NaN	NaN	5.0	3.0	NaN	NaN
2	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	1.0	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	NaN	NaN	NaN	NaN	2.0	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN

5 rows × 1664 columns





Système de recommandation

Système de recommandation en python

Étape de mise en œuvre 9

- Tri des films les mieux notés

```
In [15]: ratings.sort_values('num of ratings', ascending=False).head(10)
```

```
Out[15]:
```

	rating	num of ratings
title		
Star Wars (1977)	4.359589	584
Contact (1997)	3.803536	509
Fargo (1996)	4.155512	508
Return of the Jedi (1983)	4.007890	507
Liar Liar (1997)	3.156701	485
English Patient, The (1996)	3.656965	481
Scream (1996)	3.441423	478
Toy Story (1995)	3.878319	452
Air Force One (1997)	3.631090	431
Independence Day (ID4) (1996)	3.438228	429



Système de recommandation

Système de recommandation en python

Étape de mise en œuvre 10

- Récupérer les évaluations des utilisateurs pour deux Films
- *Star wars (1997)*
- *Liar Liar (1997)*

```
In [17]: starwars_user_ratings = moviemat['Star Wars (1977)']  
liarliar_user_ratings = moviemat['Liar Liar (1997)']  
starwars_user_ratings.head()
```

```
Out[17]: user_id  
0      5.0  
1      5.0  
2      5.0  
3      NaN  
4      5.0  
Name: Star Wars (1977), dtype: float64
```



Système de recommandation

Système de recommandation en python

Étape de mise en oeuvre 11

- Utilisez la méthode `corrwith()` pour obtenir la corrélation entre nos films les mieux notés.

```
In [18]: similar_to_starwars = moviemat.corrwith(starwars_user_ratings)
         similar_to_liarliar = moviemat.corrwith(liarliar_user_ratings)

C:\Users\jawad\anaconda3\lib\site-packages\numpy\lib\function_base.py:2634: RuntimeWarning: Degrees of freedom <= 0 for slice
  c = cov(x, y, rowvar, dtype=dtype)
C:\Users\jawad\anaconda3\lib\site-packages\numpy\lib\function_base.py:2493: RuntimeWarning: divide by zero encountered in true_
divide
  c *= np.true_divide(1, fact)
```

Erreur !



Système de recommandation

Système de recommandation en python

Étape de mise en œuvre 12

Erreur !

Supprimons-la.

```
In [19]: corr_starwars = pd.DataFrame(similar_to_starwars, columns=['Correlation'])  
corr_starwars.dropna(inplace=True)  
corr_starwars.head()
```

Out[19]:

	Correlation
title	
'Til There Was You (1997)	0.872872
1-900 (1994)	-0.645497
101 Dalmatians (1996)	0.211132
12 Angry Men (1957)	0.184289
187 (1997)	0.027398

Nettoyer tous les NaN et utiliser les DataFrame au lieu des séries



Systeme de recommandation

Systeme de recommandation en python

Étape de mise en œuvre 13

Tri par Correlation

```
In [20]: corr_starwars.sort_values('Correlation',ascending=False).head(10)|
```

Out[20]:

	Correlation
title	
Commandments (1997)	1.0
Cosi (1996)	1.0
No Escape (1994)	1.0
Stripes (1981)	1.0
Man of the Year (1995)	1.0
Hollow Reed (1996)	1.0
Beans of Egypt, Maine, The (1994)	1.0
Good Man in Africa, A (1994)	1.0
Old Lady Who Walked in the Sea, The (Vieille qui marchait dans la mer, La) (1991)	1.0
Outlaw, The (1943)	1.0



Systeme de recommandation

Systeme de recommandation en python

Etape de mise en oeuvre 14

Filtrer les films ayant moins de 100 critiques

```
In [21]: corr_starwars = corr_starwars.join(ratings['num of ratings'])
corr_starwars.head()
```

Out[21]:

	Correlation	num of ratings
title		
'Til There Was You (1997)	0.872872	9
1-900 (1994)	-0.645497	5
101 Dalmatians (1996)	0.211132	109
12 Angry Men (1957)	0.184289	125
187 (1997)	0.027398	41



Systeme de recommandation

Systeme de recommandation en python

Etape de mise en oeuvre 15

Enfin, filtrer les titres pour qu'ils aient un sens

```
In [22]: corr_starwars[corr_starwars['num of ratings']>100].sort_values('Correlation',ascending=False).head()
```

Out[22]:

	Correlation	num of ratings
title		
Star Wars (1977)	1.000000	584
Empire Strikes Back, The (1980)	0.748353	368
Return of the Jedi (1983)	0.672556	507
Raiders of the Lost Ark (1981)	0.536117	420
Austin Powers: International Man of Mystery (1997)	0.377433	130



Quiz Time

Pourquoi les moteurs de recommandation deviennent-ils populaires ?

- A) Les utilisateurs ont moins de temps, plus d'options et sont confrontés à une surcharge d'informations.
- B) Il est obligatoire d'avoir un moteur de recommandation selon les règles des télécommunications
- C) Il est préférable de recommander que de demander à l'utilisateur de faire une recherche sur son téléphone portable.
- D) Les utilisateurs ne savent pas ce qu'ils veulent



Quiz Time

Pourquoi les moteurs de recommandation deviennent-ils populaires ?

- A) Les utilisateurs ont moins de temps, plus d'options et sont confrontés à une surcharge d'informations.
- B) Il est obligatoire d'avoir un moteur de recommandation selon les règles des télécommunications
- C) Il est préférable de recommander que de demander à l'utilisateur de faire une recherche sur son téléphone portable.
- D) Les utilisateurs ne savent pas ce qu'ils veulent



Félicitations !

Merci beaucoup !!!!!